

Relatório Técnico – Redes Neurais I

Monitoramento Preditivo e Análise Inteligente de Incidentes em Ambientes Bancários Cloud-Native

Márcia Aparecida Rodrigues de Sousa

1. Descrição do Problema

O projeto aborda o desafio de prever incidentes operacionais em ambientes bancários modernos baseados em microsserviços e containers. Esses sistemas geram grandes volumes de métricas (CPU, memória, taxa de erros, latência p95), tornando difícil identificar falhas de forma antecipada. O problema consiste em classificar se ocorrerá um incidente nos próximos H passos temporais, a partir de janelas históricas de métricas de observabilidade.

2. Justificativa da Escolha

- Relevância prática: incidentes em sistemas bancários impactam diretamente clientes e operações financeiras.
- Complexidade realista: ambientes cloud-native apresentam alta variabilidade e interdependência entre serviços.
- Aderência acadêmica: uso de dataset sintético permite simulação controlada sem expor dados sensíveis, mantendo alinhamento regulatório.
- Valor estratégico: antecipar incidentes possibilita ações preventivas, reduzindo riscos e custos operacionais.

3. Por que Redes Neurais?

- Capacidade de modelar padrões complexos: redes neurais conseguem capturar relações não lineares entre métricas.
- Modelagem temporal: arquiteturas recorrentes (LSTM) são adequadas para séries temporais, pois aprendem dependências sequenciais.
- Flexibilidade: permitem combinar múltiplas métricas de observabilidade em uma única representação.
- Aplicabilidade em AIOps: redes neurais são amplamente utilizadas em monitoramento inteligente e automação de operações de TI.

3. Escolha do Modelo e Arquitetura

3.1. Baseline – MLP (Multilayer Perceptron):

- Entrada achatada (30 passos × 4 métricas = 120 atributos).
- Camadas densas com 64 e 32 neurônios (ReLU) + Dropout.
- Saída sigmoide para classificação binária.
- Justificativa: simplicidade, interpretabilidade e comparação inicial.

3.2. Modelo principal – LSTM (Long Short-Term Memory):

- Camada LSTM com 64 unidades para capturar dependências temporais.
- Camada densa com 32 neurônios (ReLU) + Dropout.
- Saída sigmoide para classificação binária.
- Justificativa: capacidade superior de modelar sequências e padrões temporais, mais adequado para métricas de observabilidade.

4. Treinamento:

- Split temporal (70% treino, 15% validação, 15% teste).
- EarlyStopping monitorando PR-AUC.
- Class weights para lidar com desbalanceamento.

5. Discussão dos Resultados

5.1. Desempenho dos modelos:

- Ambos alcançaram Recall ~0.54 e Precisão ~0.71.
- F1-Score em torno de 0.61, indicando equilíbrio razoável.
- ROC-AUC ~0.57 (moderado), PR-AUC ~0.71 (bom para classes raras).
- LSTM apresentou leve vantagem em Recall e F1-Score, confirmando sua capacidade de capturar dependências temporais.
- MLP serviu como baseline sólido, com desempenho semelhante.

5.2. Interpretação crítica:

- O PR-AUC elevado mostra que os modelos conseguem distinguir incidentes em cenários desbalanceados.
- O ROC-AUC moderado indica espaço para melhorias na separação entre classes.

- O trade-off entre Recall e Precisão reflete a realidade de AIOps: é preferível aumentar Recall (detectar mais incidentes) mesmo com mais falsos positivos.

6. Limitações:

- Dataset sintético simplificado.
- Rotulagem heurística baseada em risco.
- Prevalência da classe positiva depende do horizonte H.

7. Possíveis melhorias:

- Testar arquiteturas mais avançadas (Transformers, CNN para séries temporais).
- Ajustar thresholds de decisão por custo operacional.
- Incluir logs e variáveis adicionais.
- Escalar para datasets reais com milhões de métricas e uso de GPUs.

8. Conclusão

O projeto demonstrou que redes neurais (MLP e LSTM) são capazes de antecipar incidentes em ambientes bancários cloud-native, mesmo em cenários desbalanceados. O LSTM mostrou-se mais adequado para dados sequenciais, enquanto o MLP serviu como baseline interpretável. Apesar das limitações do dataset sintético, os resultados evidenciam o potencial das redes neurais em AIOps bancário, apoiando monitoramento preditivo e gestão inteligente de incidentes.